



Modelo Predictivo de Resultados de Partidos de la Premier League (2017/2025)

Anakin Benavides · Sebastián Valdovinos

Profesor Guía: Pablo Hernán Schwarzenberg Riveros

Junio 2026

Índice

1	Introducción	3
2	Contexto del Problema	3
2.1	La Premier League como objeto de estudio	3
2.2	Complejidad del problema de predicción	4
2.3	Relevancia del mercado de apuestas como benchmark	4
3	Objetivos del Proyecto	5
3.1	Objetivo General	5
3.2	Objetivos Específicos	5
4	Estado del Arte	5
4.1	Panorama general de la predicción en fútbol	5
4.2	Trabajos analizados	6
4.2.1	Vujčić et al. (2026) — Supervised ML Methods in Predicting EPL Game Outcomes	7
4.2.2	Ajulo y Tiamiyu (2026) — ML Model for Analysis and Prediction of Football Match Outcomes in the EPL	8
4.2.3	Ravichandran (2026) — A Machine Learning Framework for Team Success Classification in Professional Football	8
4.2.4	Chowdary (2026) — A Dynamic Relative Probability Matrix Fra- mework for Sports Outcome Prediction	8
4.2.5	Ridall et al. (2025) — Bayesian State-Space Models for the Mo- delling and Prediction of EPL Football	9
4.2.6	Howell et al. (2026) — Winning in Premier League 2: a Statistical Model of Technical Performance Indicators	9
4.2.7	Sjöberg (2023) — Football Match Prediction Using Machine Lear- ning	9
4.2.8	Rico-González et al. (2023) — Machine Learning Application in Soccer: A Systematic Review	9
4.2.9	IJMCMC Vol. 13 N°2 (2022) — Prediction of Football Match Results	10
4.2.10	Baboota y Kaur (2019) — Predictive Analysis and Modelling Football Results Using Machine Learning Approach for EPL . .	10
4.3	Síntesis y brechas identificadas	10
5	Ingeniería del Proyecto	11
5.1	Arquitectura general de la solución	11

5.2	Descripción del dataset	12
5.3	Feature Engineering	12
5.4	Modelado y resultados obtenidos	13
5.4.1	Configuración experimental	13
5.4.2	Resultados comparativos	13
5.4.3	Importancia de features	15
5.4.4	Evolución del modelo entre versiones	17
5.5	Plan de Implementación — Sprint	18
5.5.1	Trabajo completado	18
5.5.2	Plan de trabajo pendiente — Sprint de 4 semanas	18
6	Referencias	20
7	Repositorio del Proyecto	22

1. Introducción

La predicción de resultados deportivos ha experimentado un crecimiento exponencial en la última década, impulsado por la disponibilidad masiva de datos estadísticos y el avance de las técnicas de aprendizaje de máquinas (*machine learning*). En particular, el fútbol de élite —y la Premier League inglesa como su exponente más popular a nivel mundial— genera millones de datos por temporada: estadísticas de partidos, métricas individuales de jugadores, datos de rendimiento físico y señales del mercado de apuestas, entre otros.

En este contexto, el presente proyecto de título tiene como propósito central desarrollar un modelo predictivo capaz de anticipar el resultado de partidos de la Premier League, utilizando técnicas supervisadas de aprendizaje de máquinas y un conjunto de datos histórico construido especialmente para este fin. El período de análisis abarca ocho temporadas completas (2017/2018 a 2024/2025), lo que entrega una base sólida y representativa del comportamiento reciente de la liga.

La motivación de este trabajo radica en la brecha existente entre los sistemas de predicción disponibles en la literatura —mayoritariamente basados en estadísticas básicas como goles y puntos acumulados— y la riqueza de datos contextuales disponibles hoy, como la forma reciente de los equipos, las características del plantel, el rendimiento de los porteros y las señales implícitas del mercado de apuestas. La hipótesis central es que la incorporación de estas variables enriquece significativamente la capacidad predictiva del modelo, superando tanto los enfoques clásicos como el desempeño del mercado de apuestas como *benchmark* de referencia.

El trabajo se estructura en las siguientes secciones: contexto del problema (Sección 2), objetivos del proyecto (Sección 3), estado del arte (Sección 4) e ingeniería del proyecto (Sección 5).

2. Contexto del Problema

2.1. La Premier League como objeto de estudio

La Premier League es la liga de fútbol profesional más seguida del mundo, con una audiencia estimada de 3.200 millones de personas en más de 189 países. Cada temporada se disputan 380 partidos entre los 20 clubes participantes, generando un volumen considerable de datos estadísticos, económicos y de rendimiento deportivo. Esta combinación de masividad, competitividad y disponibilidad de datos hace de la Premier League un caso de estudio ideal para el análisis predictivo mediante técnicas de aprendizaje de máquinas.

A diferencia de otras ligas europeas, la Premier League se caracteriza por una alta competitividad entre los equipos: el diferencial de calidad entre el primer y el último clasificado es menor que en las ligas española, alemana o italiana, lo que incrementa la incertidumbre en los resultados y dificulta la predicción. Este fenómeno —conocido como *competitive balance*— implica que incluso los equipos con menor presupuesto pueden derrotar a los favoritos, generando una tasa natural de resultados impredecibles que ningún modelo puede eliminar completamente.

2.2. Complejidad del problema de predicción

La predicción del resultado de un partido de fútbol es un problema de clasificación binaria (victoria local vs. no victoria local), con tres características que lo diferencian de otros dominios de clasificación:

- **Alta variabilidad intrínseca:** incluso entre equipos de calidad similar, el resultado depende de factores difícilmente cuantificables, como el estado físico puntual de los jugadores clave, las condiciones climatológicas o las decisiones tácticas del partido.
- **Distribución de clases desequilibrada:** históricamente, en la Premier League el equipo local gana aproximadamente el 44–47 % de los partidos. Este desequilibrio dificulta la predicción correcta de las victorias visitantes.
- **Dependencia temporal:** el rendimiento de los equipos evoluciona a lo largo de la temporada. Un modelo que no respete el orden cronológico de los datos incurrirá en *data leakage*, sobreestimando su desempeño real.

El *dataset* construido para este proyecto comprende 3.634 partidos con 98 variables por observación. La variable objetivo (`target_home_win`) es binaria: toma el valor 1 si el equipo local gana el partido y 0 en caso contrario.

2.3. Relevancia del mercado de apuestas como benchmark

El mercado de apuestas deportivas incorpora de forma eficiente la información pública disponible sobre cada partido. Las casas de apuestas emplean analistas expertos y modelos sofisticados para fijar sus cuotas, y se estima que su precisión predictiva ronda el 62–65 % para el resultado binario de victoria local. Superar este umbral con un modelo basado exclusivamente en datos históricos y estadísticas representa un indicador sólido de valor añadido. En este proyecto, el *baseline* del mercado de apuestas alcanza un *accuracy* del 62,97 %.

3. Objetivos del Proyecto

3.1. Objetivo General

Desarrollar un modelo de aprendizaje de máquinas capaz de predecir el resultado (victoria local o no victoria local) de partidos de la Premier League inglesa, a partir de datos históricos de las temporadas 2017/2018 a 2024/2025, superando el desempeño del mercado de apuestas como referencia de comparación.

3.2. Objetivos Específicos

1. Recolectar, limpiar y consolidar datos históricos de partidos de la Premier League desde la temporada 2017/2018, incluyendo estadísticas de rendimiento, calidad de planteles y cuotas del mercado de apuestas.
2. Diseñar e implementar un proceso de *feature engineering* que capture la forma reciente de los equipos (ventana móvil de 5 partidos), el historial de enfrentamientos directos, métricas de calidad del plantel y rendimiento de porteros.
3. Entrenar y comparar múltiples algoritmos de clasificación supervisada: Gradient Boosting, Random Forest, Regresión Logística, SVM (RBF), MLP y Red Neuronal con PyTorch, aplicando validación cruzada temporal (*TimeSeriesSplit*).
4. Evaluar el desempeño de los modelos mediante métricas de clasificación (*accuracy*, F1-Score, ROC-AUC y Brier Score) y comparar los resultados contra el *baseline* del mercado de apuestas.
5. Aplicar análisis de interpretabilidad (SHAP values e importancia de features Gini) para identificar los factores más relevantes en la predicción y validar que no exista *data leakage* en las variables construidas.
6. Documentar el proceso completo en un informe académico formal y preparar una presentación de los resultados para la defensa del proyecto de título.

4. Estado del Arte

4.1. Panorama general de la predicción en fútbol

La aplicación de técnicas de aprendizaje de máquinas al fútbol ha sido abordada desde múltiples perspectivas en la literatura científica. Los primeros trabajos —predominantes en la década de 2000— utilizaban modelos estadísticos clásicos como la regresión de Poisson y los modelos de Dixon-Coles para estimar la distribución de goles. A partir

de 2015, el acceso a datos más ricos y el desarrollo de algoritmos de *ensemble learning* provocaron un giro hacia enfoques de *machine learning*, con Gradient Boosting y Random Forest como los métodos más frecuentemente reportados.

La revisión realizada para este proyecto identifica dos paradigmas predominantes: el enfoque de clasificación directa del resultado mediante ML supervisado, y el enfoque probabilístico-estadístico basado en modelos de conteo de goles y sistemas dinámicos de estado. Ambas líneas convergen en la Premier League como liga de referencia y en la necesidad de capturar la evolución temporal de la fuerza de los equipos.

4.2. Trabajos analizados

La Tabla 1 resume los diez trabajos revisados para este proyecto.

Cuadro 1: Comparación de trabajos revisados: liga, dataset, resultado y aporte principal.

Referencia	Liga / Contexto	Dataset	Mejor resultado	Limitación / Aporte
Vujčić et al. (2026)	EPL — fbref.com	Temporada 2018–2019	RF: 77,01 %	7 algoritmos comparados; sin validación temporal cronológica.
Ajulo & Tiamiyu (2026)	EPL 2021–2025	5 temporadas, football-data.co.uk	RF: 87,14 % AUC: 99 %	Resultados muy altos; posible sobreajuste. Integra Streamlit.
Ravichandran (2026)	EPL — CRISP-DM	Kaggle EPL Players 1992–2019	GBM + SHAP	Metodología CRISP-DM completa; SHAP para interpretabilidad.
Chowdary (2026)	IPL + EPL (validación)	IPL 2008–2024, 457 partidos	RPM > Elo ($p = 0,003$)	Framework novedoso de matrices de probabilidad relativa.

Continúa en la siguiente página...

Referencia	Liga / Contexto	Dataset	Mejor resultado	Limitación / Aporte
Ridall et al. (2025)	EPL 1992–2024	Historial completo EPL	Bayes.BV.VB: RPS 17,55	Modelo Bayesiano estado-espacio; publicado en JRSS-C.
Howell et al. (2026)	Premier League 2 (PL2)	367 partidos, Wyscout 2022–2025	Reg. logística: 58,3 %, AUC=0,771	KPIs en liga de reservas. Aporta perspectiva defensiva.
Sjöberg (2023)	Bundesliga	1 temporada, 306 partidos	Reg. logística: 63 %	Bajo volumen de datos; validación cronológica 70/30.
Rico-González et al. (2023)	Revisión sistemática (32 estudios)	Múltiples ligas, 2010–2022	RF, DT, KNN: 50–78 %	Mayoría de datasets no son públicos; baja reproducibilidad.
IJMCMC Vol. 13 N°2 (2022)	Deportes variados (ski, fútbol)	Múltiples datasets	SVM, RF, KNN: varía	Enfoque en edge computing móvil; no específico de EPL.
Baboota & Kaur (2019)	Premier League	11 temporadas (2005–2016)	GB: RPS 0,2156	Solo stats básicas; no incluye porteros ni calidad de plantel.

4.2.1. Vujčić et al. (2026) — Supervised ML Methods in Predicting EPL Game Outcomes

Este trabajo, publicado en *Technical Journal* (ISSN 1846-6168), es el más directamente comparable al presente proyecto en términos de liga y algoritmos evaluados. Los autores recopilan datos desde fbref.com para una temporada de la EPL y evalúan siete algoritmos de clasificación supervisada: regresión logística, Naive Bayes, árboles de decisión, k-NN, Random Forest, AdaBoost y MLP. El modelo de Random Forest alcanza la mayor *accuracy* promedio con un 77,01 %, mientras que k-NN obtiene el peor desempeño con un 63,79 %. Una limitación notable es que el estudio aplica partición

Train/Test sin validación cronológica, lo que puede inflar los resultados al no respetar la estructura temporal de los datos.

4.2.2. Ajulo y Tiamiyu (2026) — ML Model for Analysis and Prediction of Football Match Outcomes in the EPL

Publicado en *International Journal of Research and Innovation in Applied Science* (IJRIAS), este estudio implementa tres modelos de *ensemble learning* —Random Forest, XGBoost y LightGBM— sobre cinco temporadas de la EPL (2021–2025). El resultado más destacado es que Random Forest alcanza un 87,14 % de *accuracy* y un ROC-AUC del 99 %, cifras que deben interpretarse con cautela dado el tamaño reducido del dataset y la ausencia de validación temporal estricta. El trabajo también destaca por integrar una interfaz de usuario desarrollada en Streamlit y Gradio. Las *features* utilizadas incluyen goles, tiros, corners, faltas y tarjetas, sin incorporar variables de forma *rolling* ni métricas de jugadores.

4.2.3. Ravichandran (2026) — A Machine Learning Framework for Team Success Classification in Professional Football

Este trabajo, disponible como preprint en Preprints.org, adopta explícitamente el framework CRISP-DM para estructurar el proceso de investigación. Utiliza un dataset de Kaggle con estadísticas de jugadores de la EPL entre 1992 y 2019 y compara Gradient Boosting, Random Forest y Regresión Logística. Su contribución más relevante es la aplicación de SHAP *values* para interpretar los resultados del modelo, identificando qué variables de rendimiento individual influyen más en el éxito colectivo del equipo. Adicionalmente, el autor evalúa tres métodos de selección de *features* —filtro, *wrapper* y embebido— comparando su impacto en el desempeño del modelo.

4.2.4. Chowdary (2026) — A Dynamic Relative Probability Matrix Framework for Sports Outcome Prediction

Publicado como preprint en Research Square, este trabajo propone un framework novedoso denominado Dynamic Relative Probability Matrix (RPM) que modela explícitamente la competitividad relativa entre pares de equipos, superando las limitaciones del sistema Elo. El estudio se desarrolla principalmente en el contexto del cricket IPL (457 partidos, 2008–2024), pero incluye una validación de generalización en la EPL como prueba de portabilidad del enfoque. Los resultados muestran que RPM supera significativamente a Elo ($p = 0,003$, test de McNemar).

4.2.5. Ridall et al. (2025) — Bayesian State-Space Models for the Modelling and Prediction of EPL Football

Publicado en *Journal of the Royal Statistical Society Series C: Applied Statistics* (vol. 74, 2025), este trabajo representa el referente más riguroso desde el punto de vista estadístico en la revisión bibliográfica. Los autores formulan un modelo Bayesiano de estado-espacio (SSM) que captura de forma dinámica las fortalezas atacantes y defensivas de cada equipo, así como la ventaja de jugar como local. El modelo es evaluado sobre el historial completo de la EPL (1992–2024), con entrenamiento en las primeras 18 temporadas y test en las últimas 14. El mejor modelo alcanza un Ranked Probability Score acumulado de 17,55.

4.2.6. Howell et al. (2026) — Winning in Premier League 2: a Statistical Model of Technical Performance Indicators

Publicado en *International Journal of Performance Analysis in Sport*, este trabajo examina los indicadores técnicos de rendimiento (KPIs) que predicen el resultado en la Premier League 2 (PL2), la liga de reservas sub-21. Con 367 partidos de datos provenientes de Wyscout (2022–2025) y una metodología de regresión logística binaria con eliminación hacia atrás por AIC, el estudio identifica que disparos a puerta, pases hacia atrás e intercepciones son los predictores positivos más robustos de victoria. El modelo final alcanza un 58,3 % de clasificación correcta y un AUC de 0,771.

4.2.7. Sjöberg (2023) — Football Match Prediction Using Machine Learning

Tesis de maestría de Åbo Akademi University (Finlandia), este trabajo aborda la Bundesliga 2015–2016 con un volumen de datos significativamente menor (una sola temporada, 306 partidos). Se comparan tres algoritmos —Naive Bayes, regresión logística y Random Forest— sobre tres tipos de *features*: atributos de equipo (datos FIFA), atributos de jugadores y estadísticas de partido. El mejor modelo utiliza seis atributos de equipo con regresión logística y alcanza un 63 % de *accuracy*. El trabajo subraya la importancia del volumen de datos y la correcta separación cronológica de train/-test para evitar *data leakage*. Destaca que los modelos basados en atributos de equipo superan a los de jugadores y estadísticas de partido.

4.2.8. Rico-González et al. (2023) — Machine Learning Application in Soccer: A Systematic Review

Publicado en *Biology of Sport* (Vol. 40, 2023), esta revisión sistemática analiza 32 estudios sobre el uso de *machine learning* en fútbol, siguiendo las guías PRISMA. Los estudios fueron identificados en PubMed, SPORTDiscus y Web of Science. Los trabajos

se agrupan en tres áreas: predicción de lesiones, análisis de rendimiento e identificación de talento. En el subconjunto de estudios sobre predicción de resultados, los algoritmos más utilizados fueron árboles de decisión, KNN y Random Forest, con *accuracies* que oscilan entre el 50 % y el 78 % dependiendo de la liga y el período analizado. Una limitación transversal identificada es la falta de reproducibilidad, dado que la mayoría de los datasets no son de acceso público.

4.2.9. IJMCMC Vol. 13 N°2 (2022) — Prediction of Football Match Results

Artículo publicado en *International Journal of Mobile Computing and Multimedia Communications* (DOI: 10.4018/IJMCMC.293746), disponible bajo licencia Creative Commons. El trabajo establece un sistema de reconocimiento automático de posturas en deportes mediante cámaras distribuidas y clasificación mediante SVM, Random Forest y KNN. Si bien no es específico de predicción de resultados de la EPL, la publicación contextualiza el uso de modelos de clasificación en entornos deportivos bajo restricciones de *edge computing* móvil. Las técnicas de extracción de características esqueléticas y los modelos de clasificación reportados sirven como referencia metodológica para enfoques alternativos de representación de datos deportivos.

4.2.10. Baboota y Kaur (2019) — Predictive Analysis and Modelling Football Results Using Machine Learning Approach for EPL

Publicado en *International Journal of Forecasting* (35(2), 741–755), este trabajo es especialmente relevante dado que comparte la misma liga (Premier League) y un enfoque metodológico similar al presente proyecto. El modelo de Gradient Boosting alcanzó un RPS de 0,2156 para las jornadas 6 a 38 de las temporadas 2014–2016, mientras que las casas de apuestas (Bet365 y Pinnacle) obtuvieron un RPS de 0,2012. Se utilizaron *features* de forma dinámica similares al `diff_roll_points` de este proyecto y *ratings* FIFA. Sin embargo, el dataset no incluía estadísticas de porteros, métricas individuales de jugadores ni señales del mercado de apuestas, limitaciones que el presente trabajo aborda explícitamente.

4.3. Síntesis y brechas identificadas

Del análisis comparativo de los diez trabajos revisados se identifican cuatro brechas principales que el presente proyecto aborda:

- **Validación temporal rigurosa:** de los trabajos revisados, solo Ridall et al. (2025) y parcialmente Chowdary (2026) aplican separación cronológica estricta entre entrenamiento y test. Este proyecto implementa *TimeSeriesSplit* con cinco

folds cronológicos como estándar metodológico.

- **Riqueza del *feature set*:** la mayoría de los trabajos se limita a estadísticas básicas de partido. El presente proyecto incorpora 98 variables que incluyen métricas de forma *rolling*, historial H2H, calidad diferencial del plantel, rendimiento de porteros e incertidumbre del mercado de apuestas.
- **Benchmark de mercado explícito:** solo Ridall et al. (2025) compara sus resultados directamente contra las probabilidades implícitas de las casas de apuestas. Este proyecto lo incorpora desde el inicio, con un *baseline* calculado de 62,97% de *accuracy*.
- **Interpretabilidad SHAP:** aunque Ravichandran (2026) aplica SHAP *values*, ninguno de los trabajos sobre predicción de resultados los usa para explicar decisiones a nivel de partido individual. Esta dimensión está planificada para la siguiente fase del proyecto.

5. Ingeniería del Proyecto

5.1. Arquitectura general de la solución

El proyecto se estructura como un *pipeline* de ciencia de datos con cinco etapas secuenciales, cada una con entregables definidos y validaciones de calidad incorporadas. La Figura ?? resume la arquitectura general.

1. **Etapla 1 — Recolección y limpieza de datos:** consolidación de resultados históricos, estadísticas de partidos y cuotas del mercado de apuestas en un único dataset de 3.634 observaciones.
2. **Etapla 2 — Feature Engineering:** construcción de 98 variables a partir de los datos crudos, incluyendo métricas de forma reciente, *head-to-head*, calidad de plantel y porteros.
3. **Etapla 3 — Análisis Exploratorio (EDA):** análisis de distribuciones, correlaciones y selección preliminar de variables relevantes.
4. **Etapla 4 — Modelado y Evaluación:** entrenamiento de seis modelos de clasificación con validación temporal; comparación de métricas; análisis de interpretabilidad.
5. **Etapla 5 — Documentación y Entrega:** redacción del informe académico y preparación de la presentación final.

5.2. Descripción del dataset

El dataset principal (`model_dataset_enriched.csv`) contiene 3.634 partidos de la Premier League correspondientes a las temporadas 2017–2018 hasta 2024–2025. La variable objetivo es binaria (`target_home_win` $\in \{0, 1\}$), donde el valor 1 indica victoria del equipo local. La distribución de clases muestra un leve desbalance: 1.612 victorias locales (44,4 %) y 2.022 no victorias (55,6 %), como se aprecia en la Figura 1.




Figura 1: Balance de clases — `target_home_win` ($n = 3,634$ partidos).

Las 98 variables se agrupan en cuatro categorías:

1. Variables de forma reciente en ventana móvil de 5 partidos (`home/away_roll_*`).
2. Estadísticas acumuladas de temporada (`home/away_season_*`).
3. Historial de enfrentamientos directos (`h2h_*`).
4. Variables del mercado de apuestas y derivadas de jugadores (`odds_*`, `diff_squad_*`, `diff_gk_*`).

El dataset no presenta valores nulos en ninguna de sus columnas.

5.3. Feature Engineering

El proceso de construcción de variables fue iterativo y se realizó en tres versiones del modelo:

- **v1 (base):** variables de forma *rolling* (ventana de 5 partidos), estadísticas de temporada y *head-to-head*. Estas variables replican y extienden las empleadas en Baboota & Kaur (2019).
- **v2 (reducción + interacción):** eliminación de variables redundantes por alta correlación ($r > 0,85$) y creación de variables de interacción como `streak_clash` (choque de rachas invictas) y `market_form_diff` (diferencia entre forma real e implícita del mercado).

- **v3 (+jugadores):** incorporación de métricas individuales de jugadores —calidad del plantel (`diff_player_quality`), edad media del equipo (`diff_squad_age`), métricas de porteros (`diff_gk_save_pct`, `diff_gk_cs_pct`), rendimiento defensivo (`diff_team_tkl_per90`) e internacionalidad del plantel (`diff_team_int_per90`).

La Figura 2 presenta el top-20 de variables por correlación de Pearson con el *target*, donde las probabilidades implícitas del mercado de apuestas (`odds_home_prob`, `odds_away_prob`) y las diferencias de forma (`diff_roll_points`, `diff_roll_win`) lideran el ranking.




Figura 2: Top-20 *features* por correlación absoluta de Pearson con `target_home_win`.

5.4. Modelado y resultados obtenidos

5.4.1. Configuración experimental

Todos los modelos fueron entrenados utilizando validación cruzada temporal con *Time-SeriesSplit* (5 *folds*), respetando el orden cronológico de los datos. El conjunto de test final corresponde a la última temporada del dataset (2024–2025). Los hiperparámetros se fijaron por defecto en esta primera iteración, quedando el *tuning* como trabajo pendiente en la siguiente fase del proyecto.

5.4.2. Resultados comparativos

La Tabla 2 presenta el resumen de métricas para todos los modelos evaluados, incluyendo el *baseline* del mercado de apuestas. El mejor resultado en términos de *accuracy* corresponde a Gradient Boosting (74,69%), mientras que Random Forest alcanza el

mejor ROC-AUC (0,8027) y el mejor Brier Score (0,1808), indicando superioridad en la calibración de probabilidades.

Cuadro 2: Comparación de métricas en el conjunto de test para todos los modelos evaluados.

Modelo	Accuracy	Precisión	Recall	F1	ROC-AUC	Brier
Gradient Boosting	74,69 %	69,58 %	67,23 %	0,6838	0,7923	0,1815
Random Forest	73,04 %	65,82 %	70,27 %	0,6797	0,8027	0,1808
Red Neuronal (PyTorch)	73,73 %	67,33 %	68,92 %	0,6811	0,7828	0,1862
MLP (sklearn)	70,98 %	63,00 %	69,59 %	0,6613	0,7701	0,1941
Regresión Logística	70,29 %	62,05 %	69,59 %	0,6561	0,7677	0,1967
SVM (RBF)	71,11 %	63,03 %	70,27 %	0,6645	0,7663	0,1928
Baseline Mercado	62,97 %	—	—	—	—	—

Todos los modelos superan ampliamente el *baseline* del mercado de apuestas (62,97 % *accuracy*), con mejoras de entre 7 y 12 puntos porcentuales. Las Figuras 3 y 4 presentan la comparación visual de métricas y las curvas ROC para todos los modelos.

Comparando con la literatura, el 74,69% de *accuracy* de Gradient Boosting supera metodológicamente los resultados de Vujčić et al. (2026) —que no aplica validación cronológica— y los contextualiza por encima del 63 % obtenido por Sjöberg (2023) y del RPS de Baboota & Kaur (2019).




Figura 3: Comparación de métricas en conjunto de test: *accuracy*, precisión, *recall*, F1-Score y ROC-AUC.




Figura 4: Curvas ROC comparativas. Random Forest: $AUC = 0,8067$. Gradient Boosting: $AUC = 0,7950$.

5.4.3. Importancia de features

El análisis de importancia Gini para el modelo Gradient Boosting (v3) revela que `away_unbeaten_streak` —la racha consecutiva de partidos sin derrota del equipo visitante— es la variable más importante, con un valor de 0,0997, seguida por `streak_clash` (0,0601) y `odds_home_prob` (0,0577). La Tabla 3 presenta el top-10 de variables más influyentes.

Cuadro 3: Top-10 *features* por importancia Gini en Gradient Boosting v3.

#	Feature	Descripción
1	away_unbeaten_streak	Partidos consecutivos sin perder del equipo visitante
2	streak_clash	Interacción entre rachas invictas de ambos equipos
3	odds_home_prob	Probabilidad implícita de victoria local (cuotas)
4	odds_away_prob	Probabilidad implícita de victoria visitante (cuotas)
5	diff_season_gd	Diferencia de diferencia de goles acumulada (local–visitante)
6	diff_roll_points	Diferencia de puntos en ventana móvil de 5 partidos
7	diff_season_points	Diferencia de puntos acumulados en la temporada
8	home_roll_home_points	Puntos del local en sus últimos 5 partidos de local
9	market_uncertainty	Incertidumbre del mercado (dispersión de cuotas)
10	market_form_diff	Diferencia entre forma real e implícita del mercado

Este hallazgo es consistente con la literatura: Vujčić et al. (2026) y Ajulo & Tihamiyu (2026) también identifican variables de forma reciente como las más influyentes. La Figura 5 presenta la importancia completa para la versión v3 del modelo.




Figura 5: Importancia de *features* — Gradient Boosting v3 (izquierda: top-20 general; derecha: *features* de jugadores).

5.4.4. Evolución del modelo entre versiones

La Figura 6 muestra la evolución del F1-Score a través de las tres versiones del modelo para los cuatro algoritmos evaluados. Gradient Boosting y Random Forest mantienen un F1-Score estable alrededor de 0,68, sugiriendo que ya capturaban implícitamente la información de calidad de planteles a través de las cuotas del mercado. Regresión Logística y SVM mejoran más de 3 puntos porcentuales al incorporar las variables de jugadores en v3, lo que es coherente con el hallazgo de Ravichandran (2026) sobre el impacto de las métricas individuales en modelos lineales.




Figura 6: Evolución del F1-Score por versión del modelo (v1 base → v2 reducción+interacción → v3 +jugadores).

5.5. Plan de Implementación — Sprint

5.5.1. Trabajo completado

A la fecha de este informe, el equipo ha completado aproximadamente el 60 % del proyecto. La Tabla 4 resume las tareas finalizadas por integrante.

Cuadro 4: Tareas completadas por integrante al momento de este informe.

Responsable	Área	Tarea completada
Anakin Benavides	Datos	Recolección, limpieza y consolidación del dataset (3.634 partidos, 2017–2025)
Anakin Benavides	Feature Eng.	Form rolling (ventana 5 partidos): goles, puntos, tiros, corners, rachas
Anakin Benavides	Feature Eng.	Features de jugadores: porteros, calidad de plantel, edad promedio
Anakin Benavides	EDA	Análisis exploratorio: distribuciones, heatmap correlación, top features Pearson
Anakin Benavides	Modelado	Pipeline de validación temporal: TimeSeriesSplit con 5 folds cronológicos
Sebastián Valdovinos	Modelado	Entrenamiento de 6 modelos: GBM, RF, LR, SVM, MLP, Red Neuronal PyTorch
Sebastián Valdovinos	Evaluación	Comparación de métricas: accuracy, F1, ROC-AUC, Brier Score
Sebastián Valdovinos	Modelado	Iteración de versiones del modelo (v1 → v2 → v3)
Sebastián Valdovinos	Evaluación	Feature importance Gini para GBM y RF
Sebastián Valdovinos	Evaluación	Baseline del mercado de apuestas (accuracy: 62,97 %)

5.5.2. Plan de trabajo pendiente — Sprint de 4 semanas

Las tareas pendientes se organizan en un sprint de cuatro semanas, con distribución equitativa entre los dos integrantes. La Figura ?? muestra el tablero de sprint.

La Tabla 5 detalla las tareas pendientes por semana, responsable y categoría.

Cuadro 5: Plan de trabajo pendiente — sprint de 4 semanas por integrante y categoría.

Sem.	Foco	Responsable	Categoría	Tarea principal
1	Mejora modelos	Sebastián	Modelado	Hyperparameter tuning (GridSearchCV/Optuna) para GBM y RF
1	Mejora modelos	Sebastián	Validación	Calibración de probabilidades (Platt / isotónica)
1	Mejora modelos	Anakin	Validación	Verificar data leakage en <code>away_unbeaten_streak</code>
1	Mejora modelos	Anakin	Informe	Redactar introducción y contexto del problema
2	Validación avanzada	Sebastián	Validación	SHAP values sobre el mejor modelo
2	Validación avanzada	Anakin	Validación	Análisis de estabilidad del modelo por temporada
2	Validación avanzada	Anakin	Informe	Marco teórico: síntesis de los 10 papers revisados
2	Validación avanzada	Sebastián	Informe	Metodología: dataset, features y pipeline
3	Análisis y resultados	Sebastián	Visualización	Gráficos finales: SHAP summary + calibration plot
3	Análisis y resultados	Ambos	Informe	Sección de resultados y comparación vs. literatura
3	Análisis y resultados	Anakin	Informe	Discusión: limitaciones y trabajos futuros
3	Análisis y resultados	Sebastián	Validación	Análisis de errores: partidos donde el modelo falla
4	Cierre y entrega	Ambos	Informe	Conclusiones y revisión final (formato APA)
4	Cierre y entrega	Anakin	Visualización	Preparar slides y demo del modelo
4	Cierre y entrega	Sebastián	Modelado	Repositorio final: código limpio y README

6. Referencias

- Ajulo, E. B., & Tiamiyu, Q. A. (2026). A machine learning model for analysis and prediction of football match outcomes in the English Premier League. *International Journal of Research and Innovation in Applied Science (IJRIAS)*, XI(I). <https://doi.org/10.51584/IJRIAS.2026.11010020>
- Baboota, R., & Kaur, H. (2019). Predictive analysis and modelling football results using machine learning approach for English Premier League. *International Journal of Forecasting*, 35(2), 741–755. <https://doi.org/10.1016/j.ijforecast.2018.01.003>
- Chowdary, P. S. (2026). A dynamic relative probability matrix framework for sports outcome prediction. *Research Square preprint*. <https://doi.org/10.21203/rs.3.rs-9671470/v1>
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Howell, N., Groom, R., & Nicholls, S. B. (2026). Winning in Premier League 2: a statistical model of technical performance indicators. *International Journal of Performance Analysis in Sport*. <https://doi.org/10.1080/24748668.2026.2643996>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.
- Ravichandran, A. (2026). A machine learning framework for team success classification in professional football. *Preprints.org*. <https://doi.org/10.20944/preprints202605.1076.v1>
- Rico-González, M., Pino-Ortega, J., Méndez, A., Clemente, F. M., & Baca, A. (2023). Machine learning application in soccer: a systematic review. *Biology of Sport*, 40(1), 249–263. <https://doi.org/10.5114/biolsport.2023.112970>
- Ridall, P. G., Titman, A. C., & Pettitt, A. N. (2025). Bayesian state-space models for the modelling and prediction of the results of English Premier League football. *Journal of the Royal Statistical Society Series C: Applied Statistics*, 74(3), 717–742. <https://doi.org/10.1093/jrssc/qlae075>
- Sjöberg, F. (2023). *Football match prediction using machine learning* [Master's thesis, Åbo Akademi University]. Faculty of Science and Engineering, Information Technology.
- Tan, P.-N., Steinbach, M., Karpatne, A., & Kumar, V. (2019). *Introduction to Data Mining* (2nd ed.). Pearson.
- Vujičić, M., Horvat, T., Barešić, D., & Crčić, D. (2026). Supervised machine learning methods in predicting English Premier League game outcomes. *Technical Journal*,

20(2), 321–327. <https://doi.org/10.31803/tg-20240718091147>

- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29–39.
- Yin, H. (2022). Prediction of football match results: ski posture recognition via distributed cameras and edge computing. *International Journal of Mobile Computing and Multimedia Communications*, 13(2). <https://doi.org/10.4018/IJMCMC.293746>

7. Repositorio del Proyecto

El código fuente completo del proyecto —incluyendo los notebooks de análisis exploratorio y modelado, el dataset utilizado, los scripts de *feature engineering*, los resultados obtenidos y la documentación asociada— se encuentra disponible públicamente en el siguiente repositorio de GitHub:

<https://github.com/sebavaldik/>

`Modelo-de-predicci-n-de-partidos-Premier-League`

El repositorio contiene la totalidad de los archivos necesarios para reproducir los experimentos descritos en este informe, incluyendo el dataset `model_dataset_enriched.csv`, los *notebooks* de análisis exploratorio y modelado, los gráficos generados durante la evaluación de los modelos y los resultados finales obtenidos.